

N8N • PINECONE • GPT-4.1-MINI

Legal HR RAG-бот

Двухступенчатый RAG-пайплайн для кадрового и
юридического self-service сотрудников в Telegram

Портфолио аналитика • Мария Петровская

Задача и контекст

Сотрудники компании регулярно задают вопросы по кадровым регламентам и нормативной базе — ответы разбросаны по внутренним документам и законам. Ручной поиск отнимает время у HR и юристов, а качество ответа зависит от того, кто именно отвечает.

Скорость

Большинство вопросов — типовые. Нужен мгновенный ответ, без ожидания ручной обработки.

Достоверность

Ответ должен опираться на реальные документы, а не на общие знания модели.

Полнота

Если готового ответа нет в проверенном FAQ — нужен путь к полному корпусу документов.

Два эшелона поиска

ЭШЕЛОН 1

Быстрый ответ

Поиск по проверенному FAQ-неймспейсу Pinecone. Ответ уходит пользователю мгновенно, не дожидаясь проверки.



ЭШЕЛОН 2


Эскалация

Срабатывает только если FAQ не дал ответа. Параллельный поиск по полному корпусу нормативных документов.



Оба неймспейса — `faq` и `new2` — живут в одном индексе Pinecone `legis`: проверенные позиции всегда в приоритете перед сырым корпусом.

Быстрый ответ по проверенному FAQ




Ответ и проверка на «пустой результат» идут параллельно — пользователь не ждёт вторую ветку, если она не нужна.


Эскалация в полный корпус документов



ПРЯМОЙ ВЕКТОРНЫЙ ПОИСК



ВТОРОЙ AI AGENT



Пайплайн в n8n

Personal / MP Rag in low / HR bot

0 / 2Published195,781

EditorExecutionsEvaluations

Jul 9, 13:32:08
Succeeded in 9.561s | ID#472666

Copy to editor

Executions

Auto refresh

Jul 9, 13:32:08
Succeeded in 9.561s

Telegram
Updates: message

1 item

Append or update row in sheet
appendOrUpdate: sheet

1 item

Edit Fields
manual

1 item

AI Agent1
Chat Model*
Memory
Tool
2 items: total
Model

1 item

Send to Telegram3
sendMessage: message

1 item

Detect empty vector results

1 item

If

1 item

Send to Telegram4
sendMessage: message

AI Agent
Chat Model*
Memory
Tool

1 item

Send to Telegram5
sendMessage: message

OpenAI Chat Model
Vector Store (iterVector StorModel)*

1 item

Vector Store Tool

OpenAI Chat Model1

Embeddings OpenAI
512 items
Embedding*

Normalize Query

Embedding*
Embeddings

Pinecone Vector Store1

Embeddings OpenAI1

Code in JavaScript

Send to Telegram
sendMessage: message

OpenAI Chat Model2
Vector Store (iterVector StorModel)*

1 item

Vector Store Tool1

OpenAI Chat Model3

Embeddings OpenAI2

Pinecone Vector Store2

Which executions is this workflow saving?

Logs

Production workflow · Published · executions log

Инженерные решения

01 Anti-hallucination guardrail

Промпт жёстко фиксирует фразу отказа — единая точка контроля для кода ниже по пайплайну.

03 Асимметричная задержка

FAQ-ответ уходит немедленно; дожим по полному корпусу — вторым сообщением, только если нужен.

05 Google Sheets вместо БД

Легковесный аудит-лог вместо Postgres/Supabase — быстрее разворачивается, достаточно для объёма.

02 Классификатор вне LLM

Проверка «пустого результата» — дешёвый JS-узел по маркерам, а не второй вызов модели.

04 Namespace, а не индексы

faq и new2 в одном индексе — проще администрировать, сохраняя приоритет источников.

06 sessionId = chat_id

Контекстная память агента на пользователя — без дополнительной инфраструктуры.

Технологический стек

Оркестрация	n8n · production workflow (active)
Интерфейс	Telegram Bot API
LLM	OpenAI gpt-4.1-mini · 2 независимых AI Agent
Векторный поиск	Pinecone · индекс legis · namespace faq / new2
Эмбеддинги	OpenAI Embeddings · 512 dim
Логирование	Google Sheets · append/update по обращению

Мгновенный ответ из FAQ — или ссылки и развёрнутый ответ по полному корпусу

Пользователь всегда получает результат: быстрый и проверенный, либо — при отсутствии готовой позиции — обоснованный ответ поверх полного массива нормативных документов.